

15.3-15.5 Generalized Linear Models

Reference: Kevin P. Murphy, *Probabilistic Machine Learning: Advanced Topics*,
MIT Press, 2023.

장서현 (seohyun.jang@yonsei.ac.kr)¹

¹**S**ystems **M**odeling and **P**rogramming **L**ab
Department of Industrial Engineering, Yonsei University - **SYMPLY**
(<https://symply.yonsei.ac.kr/>)

IIE8560 확률모형 및 베이지안추론

Introduction & Motivation

Motivation: 왜 GLM이 필요한가?

- **Non-Gaussian Data:** 실제 데이터는 **Binary**(0/1)나 **Counts**(횟수)처럼 정규분포를 따르지 않는 경우가 많음
- **Range Constraints:** 기존 **Linear model**은 예측값이 $(-\infty, \infty)$ 범위를 가져서, 확률 $(0 \sim 1)$ 이나 횟수(양수)를 예측할 때 논리적 오류가 발생
- **Mean-Variance Relationship:** 평균이 커지면 분산도 변하는 **Heteroscedasticity** 특성을 **Variance function**을 통해 모델에 반영 가능

Solution: GLM – 선형 모델의 확률적 확장

- **Generalization of Linear Regression:** 선형 회귀가 가진 ‘가우시안 분포’와 ‘항등 연결(Identity Link)’ 제약을 해제하여 선형 모델의 틀을 유지
- **Unified Framework:** 상이한 특성을 가진 다양한 **Likelihood**들을 하나의 체계적인 최적화 루틴 안에서 통합적으로 다룸
- **Statistical Rigor:** 데이터의 실제 물리적/통계적 특성에 부합하는 확률 분포를 직접 선택함으로써 모델의 타당성을 확보
- 확장 사례: Logistic regression, Probit regression, Multilevel (hierarchical) GLMs

Logistic Regression: Model Specification (1/3)

1. **Binary Logistic Regression:** $y \in \{0, 1\}$ 인 이진 분류 문제에 사용

$$p(y|x; \theta) = \text{Ber}(y|\sigma(w^\top x + b)), \quad \sigma(a) \triangleq \frac{1}{1 + e^{-a}}$$

- $\sigma(\cdot)$ 은 sigmoid function으로, 선형 결과값을 $[0, 1]$ 확률값으로 변환

$$\log p(\mathcal{D} | \theta) = \log \prod_{n=1}^N \mu_n^{y_n} (1 - \mu_n)^{1-y_n} = \sum_{n=1}^N [y_n \log \mu_n + (1 - y_n) \log(1 - \mu_n)]$$

- e.g., 환자의 건강 지표(x)를 입력받아 특정 질병의 유무(y)를 예측하는 의료 진단 모델

2. **Multinomial Logistic Regression:** $y_n \in \{1, \dots, C\}$ 인 다중 클래스 분류 문제에 사용

$$p(y|x; \theta) = \text{Cat}(y|\text{softmax}(Wx + b)), \quad \text{softmax}(a) \triangleq \left[\frac{e^{a_1}}{\sum_{c'=1}^C e^{a_{c'}}}, \dots, \frac{e^{a_C}}{\sum_{c'=1}^C e^{a_{c'}}} \right]$$

- Softmax 함수는 선형 결과값을 각 클래스에 대한 확률값으로 변환

$$\log p(\mathcal{D} | \theta) = \log \prod_{n=1}^N \prod_{c=1}^C \mu_{nc}^{y_{nc}} = \sum_{n=1}^N \sum_{c=1}^C y_{nc} \log \mu_{nc}$$

- e.g., MNIST에서 입력 이미지(x)를 0부터 9까지의 클래스(y) 중 하나로 분류

Logistic Regression: Dealing with Class Imbalance (2/3)

1. Class Imbalance

- 특정 클래스의 샘플 수가 현저히 적은 경우, 모델이 Majority class에 편향되어 전체 정확도는 높으나 Minority class 재현율이 급격히 떨어짐
- Balanced Error Rate (BER):** 불균형한 데이터셋의 공정한 평가를 위해 클래스별 에러율의 산술 평균을 사용

$$\text{BER} = \frac{1}{C} \sum_{c=1}^C \frac{1}{N_c} \sum_{n: y_n=c} \mathbb{I}(\hat{y}_n \neq c)$$

2. Logit Adjustment

- MLE는 0-1 손실을 최소화하도록 설계되어 있어, 다수 클래스에 의해 지배되는 경향
- Logit $f_y(x)$ 에 클래스 Prior π_c 를 반영하여 **결정 경계(decision boundary)**를 보정

$$\hat{y}(x) = \arg \max_{y \in \mathcal{Y}} f_y(x) - \tau \log \pi_y$$

- Logit-Adjusted Loss: 학습 시 Softmax Cross-Entropy에 logit adjustment를 반영

$$\ell(y, f(x)) = -\log \frac{e^{f_y(x) + \tau \log \pi_y}}{\sum_{y'=1}^C e^{f_{y'}(x) + \tau \log \pi_{y'}}}$$

- 데이터 리샘플링 없이도 Fisher consistency를 유지하며 class imbalance 문제 해결

Logistic Regression: MCMC-based Posterior Prediction (3/3)

1. Goal: 파라미터 불확실성이 예측과 결정 경계에 어떻게 반영되는지를 정량화하고자 함

$$p(y | x, \mathcal{D}) = \int p(y | x, w) p(w | \mathcal{D}) dw$$

- Logistic regression에서는 $p(w | \mathcal{D})$ 가 non-Gaussian
- Sigmoid/softmax로 인해 위 적분은 closed-form 해가 없음

2. Solution: Markov Chain Monte Carlo (MCMC) Inference

- 사후분포 $p(w | \mathcal{D})$ 로부터 직접 샘플링

$$p(w | \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S \delta(w - w^{(s)}), \quad w^{(s)} \sim p(w | \mathcal{D})$$

- 예측 분포는 샘플 평균으로 근사

$$p(y = 1 | x, \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S \sigma\left((w^{(s)})^\top x\right)$$

- MCMC는 사후분포의 **전체 형태와 불확실성**을 반영할 수 있으며, 결정 경계의 위치뿐 아니라 **방향과 변동성**까지 표현 가능

Probit Regression: Latent Variable Interpretation (1/3)

Key Idea

- Probit regression은 logistic regression과 유사하지만, sigmoid 대신 **Gaussian CDF**를 사용

$$\mu_n = \Phi(a_n), \quad a_n = w^\top x_n$$

- 이에 대응하는 link function은

$$(\text{Probit Link}) \quad a_n = \Phi^{-1}(\mu_n)$$

Latent Variable Interpretation

- 관측되지 않는 잠재 변수(latent variable)를 가정

$$z_n = w^\top x_n + \varepsilon_n, \quad \varepsilon_n \sim \mathcal{N}(0, 1)$$

- 출력은 잠재 변수의 부호로 결정

$$y_n = \mathbb{I}(z_n \geq 0)$$

Marginalization

- 잠재 변수를 적분하면 probit likelihood를 회복

$$p(y_n = 1 \mid x_n, w) = \int \mathbb{I}(z_n \geq 0) \mathcal{N}(z_n \mid w^\top x_n, 1) dz_n = \Phi(w^\top x_n)$$

Probit Regression: Maximum Likelihood Estimation (2/3)

1. Direct MLE using Gradient Methods

- Probit likelihood는 미분 가능 → 표준 SGD / quasi-Newton 적용 가능
- 단일 데이터 포인트에 대한 log-likelihood gradient:

$$\nabla_w \log p(\tilde{y}_n | w^\top x_n) = x_n \frac{\tilde{y}_n \phi(\mu_n)}{\Phi(\tilde{y}_n \mu_n)}, \quad \mu_n = w^\top x_n$$

2. EM Algorithm via Latent Variable Interpretation

- **E-step:** z_n 의 사후분포는 **truncated Gaussian**

$$p(z_n | y_n, x_n, w) = \begin{cases} \mathcal{N}(w^\top x_n, 1) \mathbb{I}(z_n > 0), & y_n = 1 \\ \mathcal{N}(w^\top x_n, 1) \mathbb{I}(z_n < 0), & y_n = 0 \end{cases}$$

- **M-step:** $\mu = \mathbb{E}[z_n]$ 을 타겟으로 하는 ridge regression

$$\hat{w} = \left(V_0^{-1} + X^\top X \right)^{-1} X^\top \mu$$

- EM은 구조적으로 단순하지만 수렴이 느릴 수 있음. 실제로는 SGD / BFGS가 더 빠른 경우가 많음.

Probit Regression: Beyond Binary Outcomes (3/3)

Why Probit is Easily Extendable? Probit regression은 **latent variable + threshold** 구조를 가지며, 출력 공간의 구조(순서 유무)에 따라 자연스럽게 확장 가능

1. Ordinal Probit Regression

- 출력 클래스가 **순서를 가지는 경우** (e.g., low / medium / high, 만족도 점수, 신용 등급)
- 잠재 변수 z_n 를 여러 임계값으로 분할

$$y_n = j \quad \text{if} \quad \gamma_{j-1} < z_n \leq \gamma_j$$

- 임계값은 정렬 제약을 만족해야 함:

$$-\infty = \gamma_0 \leq \gamma_1 \leq \dots \leq \gamma_C = \infty$$

2. Multinomial Probit Regression

- 출력 클래스가 **순서 없는 범주형**인 경우 (e.g., 교통수단 선택, 제품 카테고리, 정치 성향)
- 클래스별 latent score를 정의

$$z_{nc} = w_c^T x_n + \varepsilon_{nc}, \quad \varepsilon \sim \mathcal{N}(0, R)$$

- 가장 큰 latent score를 갖는 클래스를 선택

$$y_n = \arg \max_c z_{nc}$$

- 클래스 간 **상관 구조**를 명시적으로 모델링 가능

Multilevel (Hierarchical) GLMs

Motivation 여러 개의 관련된 데이터(그룹)이 존재 (e.g., 병원별 환자 데이터, 학교별 성적)

Three Modeling Strategies

1. **No pooling**: 그룹별로 독립적인 모델 학습 → 데이터가 적은 그룹에서 overfitting
2. **Complete pooling**: 모든 데이터를 합쳐 하나의 모델 학습 → 그룹 간 차이를 무시하여 underfitting
3. **Partial pooling (Hierarchical model)**: 그룹별 파라미터를 공유된 prior로 연결

Hierarchical GLM Formulation

$$p(\theta^{0:j}, \mathcal{D}) = p(\theta^0) \prod_{j=1}^J \left[p(\theta^j | \theta^0) \prod_{n=1}^{N_j} p(y_n^j | x_n^j, \theta^j) \right]$$

- 각 그룹 j 는 고유한 파라미터 θ^j 를 가지며 그룹 파라미터들은 공통 상위 prior로부터 생성

$$\theta^j \sim p(\theta^j | \theta^0), \quad \theta^0 \sim p(\theta^0)$$

- 데이터가 적은 그룹에 대해 **shrinkage**를 유도하고, 그룹 간 정보 공유를 통해 **일반화 성능을 향상**시키며, Bayesian 추론으로 **불확실성을 정량화**

Generalized Linear Mixed Models (GLMMs)

Why GLMMs?

- 표준 GLM이 포착하지 못하는 **그룹 내 상관 구조와 의존성**을 모델링하기 위함
- 각 그룹은 고유한 효과를 가지되, 공통 구조를 공유하는 **partial pooling** 설정
- 이를 위해 그룹별 파라미터에 **Gaussian prior**를 가정

$$\theta^j \mid \theta^0 \sim \mathcal{N}(\theta^0, \Sigma)$$

- GLM likelihood와 결합하면 **Generalized Linear Mixed Model (GLMM)**

Model Formulation

- 선형 예측자는 고정 효과와 랜덤 효과의 합으로 표현

$$\eta_n = x_n^\top \theta^j = x_n^\top (\theta^0 + \epsilon^j) = x_n^\top \theta^0 + x_n^\top \epsilon^j$$

- 링크 함수 $\ell(\cdot)$ 를 통해 관측값 생성

$$p(y_n \mid x_n, g_n = j) = p(y_n \mid \ell(\eta_n))$$

Fixed vs Random Effects

- Fixed effects** θ^0 : 모든 그룹에 공통적인 전역 효과
- Random effects** $\epsilon^j \sim \mathcal{N}(0, \Sigma)$: 그룹별 편차(idiosyncratic deviations)

응용 사례 (1/3): Political Preference Modeling

Reference Paper Gelman et al. (2006), *Multilevel (Hierarchical) Modeling: What It Can and Cannot Do*, Annals of Applied Statistics

Problem Setting

- 개인의 정책 찬성 여부를 예측

$y_{ij} \in \{0, 1\}$: 주(state) j 에 속한 개인 i

- 입력 변수: 나이, 소득, 교육 수준 등 개인 특성

Challenges

- 반응 변수는 **이진(binary)** $\Rightarrow$ Gaussian 가정 부적절
- 주(state)별 정치적 성향 차이 존재
- 일부 주는 표본 수가 매우 적음

Modeling Implication

- Binary outcome $\Rightarrow$ **Logistic regression**
- 그룹 간 이질성 $\Rightarrow$ **Multilevel (hierarchical) structure**

응용 사례 (2/3): Multilevel Logistic GLMM

Model Specification

- Logit 링크를 사용하는 이진 GLM

$$\text{logit } p(y_{ij} = 1) = x_{ij}^T \theta^0 + \varepsilon^j$$

- 주(state)별 랜덤 효과

$$\varepsilon^j \sim \mathcal{N}(0, \Sigma)$$

Model Type

- Likelihood: Bernoulli
- Link function: Logit
- Structure: **Multilevel GLM / Logistic GLMM**

Inference

- Bayesian 추론 + MCMC 사용
- 데이터가 적은 주에 대해 **shrinkage** 효과
- 그룹 간 정보 공유를 통한 안정적 추정

응용 사례 (3/3): Multilevel Logistic GLMM – Results

Key Results

- 주(state)별 랜덤 효과 추정치를 통해 정치 성향의 이질성 확인
- 표본 수가 적은 주의 추정치는 전체 평균으로 **shrinkage**
- 단순 logistic regression 대비 안정적인 예측 성능

Interpretation

- 개인 특성 효과와 주별 효과를 분리하여 해석 가능
- 불확실성이 큰 주는 posterior 분산이 크게 추정됨
- 정책 효과 분석 시 과도한 과신 (overconfidence) 방지




Figure 1: Results for Multilevel (partial pooling) Regression Lines