

IIE8560 Midterm Exam

장서현 (학번: 2025324096)

문제1. 베이저안 추론 - 사후분포 및 예측분포 유도

포아송 분포를 따르는 확률 모형을 고려하자. 포아송 분포의 모수인 θ 는 미지의 양이며, 이에 대해 다음과 같은 감마 사전분포를 가정한다.

- 사전분포: $\theta \sim \text{Gamma}(\alpha_0, \beta_0)$
- 밀도함수는 다음과 같다:

$$p(\theta) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \theta^{\alpha_0-1} e^{-\beta_0 \theta}, \quad \theta > 0$$

관측된 데이터 $D = \{x_1, x_2, \dots, x_N\}$ 는 포아송 분포에서 독립적으로 추출된 샘플로 가정하며, 각 x_i 는 다음을 따른다:

$$x_i \sim \text{Poisson}(\theta)$$

(a)

- 사후분포 유도: $p(\theta|D) \sim \text{Gamma}(\alpha_0 + \sum_{i=1}^N x_i, \beta_0 + N)$

Proof.

베이즈 정리에 따르면 사후분포는 가능도(likelihood)와 사전분포(prior)의 곱에 비례함

$$p(\theta|D) \propto p(D|\theta) \cdot p(\theta)$$

1. 가능도 함수 (Likelihood)

데이터 $D = x_1, \dots, x_N$ 가 $\text{Poisson}(\theta)$ 에서 독립적으로 추출되었으므로, 전체 데이터의 가능도 함수는 각 x_i 의 확률 질량 함수(PMF)의 곱

$$p(D|\theta) = \prod_{i=1}^N p(x_i|\theta) = \prod_{i=1}^N \frac{\theta^{x_i} e^{-\theta}}{x_i!}$$

$\prod \frac{1}{x_i!}$ 항은 θ 와 무관하므로 생략하고, θ 에 대해 비례하는 항들만 정리하면,

$$p(D|\theta) \propto \left(\prod_{i=1}^N \theta^{x_i} \right) \left(\prod_{i=1}^N e^{-\theta} \right)$$

$$p(D|\theta) \propto \theta^{\sum_{i=1}^N x_i} \cdot e^{-N\theta}$$

관측 값의 합을 $S = \sum_{i=1}^N x_i$ 라 하면, 가능도는 $\theta^S e^{-N\theta}$ 에 비례함

2. 사전분포 (Prior)

주어진 사전분포는 $\text{Gamma}(\alpha_0, \beta_0)$

$$p(\theta) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \theta^{\alpha_0-1} e^{-\beta_0 \theta} \propto \theta^{\alpha_0-1} e^{-\beta_0 \theta}$$

사후분포는 가능도와 사전분포의 곱에 비례하기에,

$$p(\theta|D) \propto p(D|\theta) \cdot p(\theta)$$

$$p(\theta|D) \propto (\theta^S e^{-N\theta}) \cdot (\theta^{\alpha_0-1} e^{-\beta_0\theta})$$

θ 에 대한 항들을 결합하면

$$p(\theta|D) \propto \theta^{S+\alpha_0-1} \cdot e^{-N\theta-\beta_0\theta}$$

$$p(\theta|D) \propto \theta^{(\alpha_0+S)-1} \cdot e^{-(\beta_0+N)\theta}$$

□

정리 결과, 감마 분포의 확률 밀도 함수 커널 형태인 $\theta^{\alpha-1}e^{-\beta\theta}$ 와 일치함을 확인할 수 있다. 즉, 사후분포 $p(\theta|D)$ 는 감마 분포며, 이는 포아송 가능도와 감마 사전분포가 conjugacy에 있음 또한 의미한다.

• 사후분포의 모수

- 형상 (Shape) 모수: $\alpha_N = \alpha_0 + \sum_{i=1}^N x_i$
- 비율 (Rate) 모수: $\beta_N = \beta_0 + N$

(b)

• 제곱오차 손실(squared-error loss) 하의 베이즈 추정량

제곱오차 손실(squared-error loss) 하에서의 베이즈 추정량은 사후분포의 평균값과 일치한다.

$Gamma(\alpha, \beta)$ 분포의 평균은 $\frac{\alpha}{\beta}$ 이기에, (a)에서 유도한 사후분포 $p(\theta|D) \sim Gamma(\alpha_N, \beta_N)$ 를 이용하면

$$\begin{aligned}\hat{\theta}_{Bayes} &= \mathbb{E}[\theta|D] \\ &= \frac{\alpha_N}{\beta_N} \\ &= \frac{\alpha_0 + \sum_{i=1}^N x_i}{\beta_0 + N}\end{aligned}$$

(c)

• 사후예측분포 유도: $p(x_{new}|D) \sim NB(\alpha_0 + \sum_{i=1}^N x_i, \frac{\beta_0+N}{\beta_0+N+1})$

Proof.

사후예측분포는 θ 에 대한 사후 불확실성을 적분하여 marginalize함으로써 얻어짐

$$p(x_{new}|D) = \int_0^\infty p(x_{new}|\theta) \cdot p(\theta|D) d\theta$$

- 가능도 (Likelihood): $p(x_{new}|\theta) = Poisson(x_{new}|\theta) = \frac{\theta^{x_{new}} e^{-\theta}}{x_{new}!}$
- 사후분포 (Posterior): $p(\theta|D) = Gamma(\theta|\alpha_N, \beta_N) = \frac{\beta_N^{\alpha_N}}{\Gamma(\alpha_N)} \theta^{\alpha_N-1} e^{-\beta_N\theta}$

이를 적분식에 대입하고 정리하면

$$\begin{aligned}p(x_{new}|D) &= \int_0^\infty \left(\frac{\theta^{x_{new}} e^{-\theta}}{x_{new}!} \right) \left(\frac{\beta_N^{\alpha_N}}{\Gamma(\alpha_N)} \theta^{\alpha_N-1} e^{-\beta_N\theta} \right) d\theta \\ &= \frac{\beta_N^{\alpha_N}}{x_{new}! \cdot \Gamma(\alpha_N)} \int_0^\infty \theta^{x_{new} + \alpha_N - 1} e^{-\theta - \beta_N\theta} d\theta \\ &= \frac{\beta_N^{\alpha_N}}{x_{new}! \cdot \Gamma(\alpha_N)} \int_0^\infty \theta^{(x_{new} + \alpha_N) - 1} e^{-(\beta_N + 1)\theta} d\theta\end{aligned}$$

여기서 적분 항이 $\text{Gamma}(x_{\text{new}} + \alpha_N, \beta_N + 1)$ 분포의 커널 형태이기 때문에, 이 적분의 값은 감마 함수의 적분 공식을 통해 다음과 같이 계산됨

$$\int_0^\infty \theta^{A-1} e^{-B\theta} d\theta = \frac{\Gamma(A)}{B^A}$$

위 식에서 $A = x_{\text{new}} + \alpha_N$ 이고 $B = \beta_N + 1$ 이므로, 적분 값은 다음과 같음

$$\int_0^\infty \theta^{(x_{\text{new}} + \alpha_N) - 1} e^{-(\beta_N + 1)\theta} d\theta = \frac{\Gamma(x_{\text{new}} + \alpha_N)}{(\beta_N + 1)^{x_{\text{new}} + \alpha_N}}$$

이 결과를 원래의 식에 다시 대입하여 정리하면

$$\begin{aligned} p(x_{\text{new}}|D) &= \frac{\beta_N^{\alpha_N}}{x_{\text{new}}! \cdot \Gamma(\alpha_N)} \left[\frac{\Gamma(x_{\text{new}} + \alpha_N)}{(\beta_N + 1)^{x_{\text{new}} + \alpha_N}} \right] \\ &= \frac{\Gamma(x_{\text{new}} + \alpha_N)}{x_{\text{new}}! \cdot \Gamma(\alpha_N)} \cdot \frac{\beta_N^{\alpha_N}}{(\beta_N + 1)^{x_{\text{new}} + \alpha_N}} \\ &= \frac{\Gamma(x_{\text{new}} + \alpha_N)}{x_{\text{new}}! \cdot \Gamma(\alpha_N)} \cdot \frac{\beta_N^{\alpha_N}}{(\beta_N + 1)^{\alpha_N} \cdot (\beta_N + 1)^{x_{\text{new}}}} \\ &= \frac{\Gamma(x_{\text{new}} + \alpha_N)}{x_{\text{new}}! \cdot \Gamma(\alpha_N)} \cdot \left(\frac{\beta_N}{\beta_N + 1} \right)^{\alpha_N} \cdot \left(\frac{1}{\beta_N + 1} \right)^{x_{\text{new}}} \end{aligned}$$

정리 결과, 사후예측분포의 PMF는 Negative Binomial distribution의 형태를 띠를 확인

- 성공 횟수 (r): $r = \alpha_N = \alpha_0 + \sum_{i=1}^N x_i$
- 성공 확률 (p): $p = \frac{\beta_N}{\beta_N + 1} = \frac{\beta_0 + N}{\beta_0 + N + 1}$

□

문제2. 베이زي안 의사결정과 엔트로피

(a)

• 베이즈 위험(Bayes Risk)의 정의

베이즈 위험(Bayes risk)은 관측 x 가 주어졌을 때, 특정 행동 a 를 선택함에 따라 사후 확률(posterior)을 고려하여 계산된 평균적인 손실의 기댓값을 의미한다. 즉, 우리가 완벽한 정보를 가지고 있지 않기 때문에 ($\rightarrow$ hidden state h 를 직접 알 수 없음), x 라는 데이터를 바탕으로 추정된 사후 확률 $p(h|x)$ 을 가중치로 사용한다. 따라서, 베이즈 위험은 posterior expected loss로도 정의할 수 있으며, 이는 true state이 h 일때 우리가 선택한 행동 a 사이의 손실 $l(h, a)$ 에 이 사후 확률을 곱하여 모두 더한 값이다.

$$\rho(a|x) \equiv \mathbb{E}_{p(h|x)}[l(h, a)] = \sum_{h \in \mathcal{H}} l(h, a) p(h|x)$$

• 베이즈 최적 결정 규칙(Bayes optimal decision rule)과의 관계

베이즈 최적 결정 규칙(Bayes optimal decision rule)은 현재 가진 정보(x) 하에서 예상되는 손실(베이즈 위험)을 최소화하는 행동을 선택하는 규칙이다. 베이즈 위험 $\rho(a|x)$ 는 우리가 행동 a 를 선택했을 때 평균적으로 감수해야 할 손실을 정량화한 값이다. 합리적인 의사 결정자라면 가능한 모든 행동 $\mathcal{A}$ 중에서 이 예상 손실을 가장 작게 만드는 행동 $\pi^*(x)$ 를 선택할 것이다. 따라서 베이즈 위험을 최소화하는 것이 곧 베이즈 최적 결정 규칙으로 이어진다.

$$\pi^*(x) = \arg \min_{a \in \mathcal{A}} \rho(a|x)$$

• 0-1 손실함수와 MAP 규칙

0-1 손실함수(zero-one loss)는 이진분류 문제에서 사용되며, 예측이 맞으면 손실이 0, 틀리면 손실이 1인 함수이다. 이진 분류에서는 실제 클래스 y^* 와 예측 클래스 $\hat{y}$ 모두 $\mathcal{Y} = \{0, 1\}$ 에 속한다.

$$l_{01}(y^*, \hat{y}) = 1\{y^* \neq \hat{y}\}$$

이진분류 문제에서 취할 수 있는 행동(예측)은 $\hat{y} = 0$ 또는 $\hat{y} = 1$ 두 가지뿐이다. 각 행동의 베이즈 위험을 계산해보면,

- $\hat{y} = 0$ 으로 예측할 때의 위험:

예측 $\hat{y} = 0$ 이 틀릴 경우, 즉 실제 $y^* = 1$ 일 때만 손실 1이 발생

$$\begin{aligned}\rho(\hat{y} = 0|x) &= \sum_{y^* \in \{0,1\}} 1(y^* \neq 0) \cdot p(y^*|x) \\ &= [1(0 \neq 0) \cdot p(y^* = 0|x)] + [1(1 \neq 0) \cdot p(y^* = 1|x)] \\ &= [0 \cdot p(y^* = 0|x)] + [1 \cdot p(y^* = 1|x)] \\ &= p(y^* = 1|x)\end{aligned}$$

- $\hat{y} = 1$ 로 예측할 때의 위험:

예측 $\hat{y} = 1$ 이 틀릴 경우, 즉 실제 $y^* = 0$ 일 때만 손실 1이 발생

$$\begin{aligned}\rho(\hat{y} = 1|x) &= \sum_{y^* \in \{0,1\}} 1(y^* \neq 1) \cdot p(y^*|x) \\ &= [1(0 \neq 1) \cdot p(y^* = 0|x)] + [1(1 \neq 1) \cdot p(y^* = 1|x)] \\ &= [1 \cdot p(y^* = 0|x)] + [0 \cdot p(y^* = 1|x)] \\ &= p(y^* = 0|x)\end{aligned}$$

베이지 최적 결정은 두 행동의 위험 중 더 낮은 쪽을 선택하는 것이다.

- $\rho(\hat{y} = 0|x) < \rho(\hat{y} = 1|x)$ 이면, 즉 $p(y^* = 1|x) < p(y^* = 0|x)$ 이면 $\hat{y} = 0$ 을 선택
- $\rho(\hat{y} = 1|x) < \rho(\hat{y} = 0|x)$ 이면, 즉 $p(y^* = 0|x) < p(y^* = 1|x)$ 이면 $\hat{y} = 1$ 을 선택

$\hat{y}$ 로 예측할 때의 위험 $\rho(\hat{y}|x)$ 는 곧 "예측이 틀릴 확률" $\mathbb{P}(y^* \neq \hat{y}|x)$ 을 의미한다. 전체 확률은 1이므로, 이 위험은 $1 - \mathbb{P}(y^* = \hat{y}|x)$ 로도 표현할 수 있다. 베이지 최적 결정은 위험 $\rho(\hat{y}|x)$ 를 최소화하는 것이므로, $1 - p(y^* = \hat{y}|x)$ 를 최소화해야 하며, 이는 $p(y^* = \hat{y}|x)$ 를 최대화하는 것과 같다. 따라서, 0-1 손실함수 하에서의 최적의 예측 $\hat{y}(x)$ 는 사후 확률 $p(y|x)$ 를 가장 크게 만드는 클래스 y 를 선택해야 한다.

$$\hat{y}(x) = \arg \max_{y \in \mathcal{Y}} p(y|x)$$

이는 사후 확률을 최대로 하는(Most A Posteriori, MAP) 규칙의 정의와 일치한다.

(b)

• 엔트로피의 의미와 불확실성 정량화

세넨 엔트로피 $H[P]$ 는 확률분포 P 가 가지는 평균 정보량 또는 불확실성을 정량화하는 척도이다.

- 자기 정보 (Self-information): 확률 p 를 가진 단일 사건이 발생했을 때의 정보량은 $I(p) = -\log(p)$ 로 정의된다.
 - * 드문 사건 ($p \approx 0$): 발생 확률이 매우 낮은 사건이 실제로 일어나면, 많은 정보를 얻으며 이때 $I(p)$ 값은 매우 크다.
 - * 확실한 사건 ($p \approx 1$): 거의 확실하게 일어날 사건이 일어나면, 많은 정보를 얻지 못하며 이때 $I(p)$ 값은 0에 가깝다.
- 엔트로피 (Entropy): 세넨 엔트로피 $H[P]$ 는 자기정보를 모든 가능한 사건 i 에 대해 평균낸 값이다. 즉, 각 사건의 정보량($-\log(p_i)$)에 해당 사건이 일어날 확률(p_i)을 곱하여 모두 더한 기댓값이다.

$$H[P] = - \sum_i p_i \log p_i$$

- * 최대 엔트로피 (높은 불확실성): 시스템이 완전히 무작위적이어서 모든 사건이 동일한 확률로 일어날 때 (즉, 균등 분포일 때) 엔트로피는 최대가 된다.
- * 최소 엔트로피 (낮은 불확실성): 시스템의 상태가 변동 없이 유일하게 결정될 때 (즉, 하나의 사건만 확률이 1이고 나머지는 0일 때) 엔트로피는 최소가 된다. 분포가 한쪽으로 치우칠수록 확실성이 높아져 엔트로피는 줄어든다.

• 두 개의 이산 확률분포를 통한 예시

동전 던지기 시행을 나타내는 이산 확률 변수(discrete random variable) X 를 정의하고 X 가 가질 수 있는 값의 집합(표본 공간)을 $\mathcal{X}$ 라고 정의한다.

$$\mathcal{X} = \{x_1(\text{앞면}), x_2(\text{뒷면})\}$$

X 의 확률 분포는 확률 질량 함수 $p(x) = P(X = x)$ 로 정의되며, 확률 변수 X 의 엔트로피 $H(X)$ 는 다음과 같이 정의한다.

$$H(X) = - \sum_{i=1}^{|\mathcal{X}|} p(x_i) \log_2 p(x_i)$$

이 경우 $|\mathcal{X}| = 2$ 이므로, $H(X) = -[p(x_1) \log_2 p(x_1) + p(x_2) \log_2 p(x_2)]$ 이다.

- 예시 1: 낮은 엔트로피 (결정적인 상황)

확률 분포 (P_A):

$$p_A(x_1) = 0.99 \quad (\text{앞면})$$

$$p_A(x_2) = 0.01 \quad (\text{뒷면})$$

엔트로피 계산:

$$\begin{aligned} H(P_A) &= -[p_A(x_1) \log_2 p_A(x_1) + p_A(x_2) \log_2 p_A(x_2)] \\ &= -[0.99 \cdot \log_2(0.99) + 0.01 \cdot \log_2(0.01)] \\ &\approx 0.0808 \text{ bits} \end{aligned}$$

분포 P_A 는 확률이 x_1 에 집중되어 있다. 이는 시스템의 상태가 거의 유일하게 결정됨을 의미하며, 관측 전의 불확실성이 매우 낮다. 따라서 엔트로피 값 $H(P_A)$ 는 0에 매우 가깝다.

- 예시 2: 높은 엔트로피 (불확실한 상황)

확률 분포 (P_B):

$$p_B(x_1) = 0.5 \quad (\text{앞면})$$

$$p_B(x_2) = 0.5 \quad (\text{뒷면})$$

엔트로피 계산:

$$\begin{aligned} H(P_B) &= -[p_B(x_1) \log_2 p_B(x_1) + p_B(x_2) \log_2 p_B(x_2)] \\ &= -[0.5 \cdot \log_2(0.5) + 0.5 \cdot \log_2(0.5)] \\ &= 1 \text{ bit} \end{aligned}$$

분포 P_B 는 표본 공간 $\mathcal{X}$ 에 대한 균등 분포다. 엔트로피는 시스템이 완전히 무작위적이어서 모든 사건이 동일한 확률로 발생할 때 최대가 된다. 표본 공간의 크기가 $n = 2$ 일 때, 엔트로피의 최댓값은 $\log_2(n) = \log_2(2) = 1 \text{ bit}$ 이며, $H(P_B) = 1$ 은 이 시스템에서 가능한 최대의 불확실성을 나타낸다.

문제3. 증명 - KL 발산은 음이 아님

- 증명: KL 발산이 항상 0 이상

Proof.

가정 $D_{KL}(P \parallel Q)$ 가 유한하려면 $p(x) > 0$ 인 모든 $x \in \mathcal{X}$ 에 대해 $q(x) > 0$ 이어야 한다($P \ll Q$). 만약 어떤 x 에서 $p(x) > 0$ 이고 $q(x) = 0$ 이면 $D_{KL}(P \parallel Q) = +\infty$ 이므로, 이 경우에도 $D_{KL} \geq 0$ 는 자명하다. 이하에서는 $P \ll Q$ 를 가정하고 증명한다.

KL 발산의 정의:

$$D_{KL}(P \parallel Q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)}$$

이 식은 로그 내부의 분수를 뒤집으면,

$$D_{KL}(P \parallel Q) = \sum_{x \in \mathcal{X}} p(x) \left[-\log \frac{q(x)}{p(x)} \right] = - \sum_{x \in \mathcal{X}} p(x) \log \frac{q(x)}{p(x)}$$

이 합은 P 분포에 대한 $-\log \left(\frac{q(x)}{p(x)} \right)$ 함수의 기댓값으로 표현 가능

$$D_{KL}(P \parallel Q) = -E_{p(x)} \left[\log \left(\frac{q(x)}{p(x)} \right) \right]$$

위 가정($P \ll Q$) 하에서 $\frac{q(x)}{p(x)}$ 는 P -almost surely(w.p. 1) 양수이므로, concave function $\log$ 에 대해 Jensen's inequality ($E[f(Y)] \leq f(E[Y])$) 적용 가능

$$E_{p(x)} \left[\log \left(\frac{q(x)}{p(x)} \right) \right] \leq \log \left(E_{p(x)} \left[\frac{q(x)}{p(x)} \right] \right)$$

좌변(LHS)과 우변(RHS)을 각각 계산해보면,

- LHS: $E_{p(x)} \left[\log \left(\frac{q(x)}{p(x)} \right) \right] = \sum_{x \in \mathcal{X}} p(x) \log \left(\frac{q(x)}{p(x)} \right)$
- RHS: $\log \left(E_{p(x)} \left[\frac{q(x)}{p(x)} \right] \right) = \log \left(\sum_{x \in \mathcal{X}} p(x) \frac{q(x)}{p(x)} \right) = \log \left(\sum_{x \in \mathcal{X}} q(x) \right)$
 - * Q 는 확률 분포이므로, $\sum_{x \in \mathcal{X}} q(x) = 1$
 - * 따라서 RHS = $\log(1) = 0$ 로 정리 가능

이 결과를 원래 부등식에 대입하면,

$$\sum_{x \in \mathcal{X}} p(x) \log \left(\frac{q(x)}{p(x)} \right) \leq 0$$

마지막으로, $D_{KL}(P \parallel Q)$ 의 정의로 돌아가면,

$$D_{KL}(P \parallel Q) = - \sum_{x \in \mathcal{X}} p(x) \log \frac{q(x)}{p(x)} \geq 0$$

□

• 증명: 오직 $P = Q$ 일때 등호 성립

Proof.

젠센 부등식 $E[f(Y)] \leq f(E[Y])$ 에서 등호가 성립하기 위해서는 f 가 오목함수며, 확률 변수 Y 가 상수여야함

즉, $D_{KL} = 0$ 가 성립하려면 $p(x) > 0$ 인 모든 $x \in \mathcal{X}$ 에 대해 $\frac{q(x)}{p(x)} = c$ 인 상수 c 가 존재해야 한다.

이는 $q(x) = c \cdot p(x)$ 임을 의미하며, 모든 x 에 대해 합을 구하면,

$$\sum_{x \in \mathcal{X}} q(x) = \sum_{x \in \mathcal{X}} c \cdot p(x)$$

$$\sum_{x \in \mathcal{X}} q(x) = c \sum_{x \in \mathcal{X}} p(x)$$

P 와 Q 모두 확률 분포이므로, 각 합은 1이기 때문에

$$1 = c \cdot 1$$

$$c = 1$$

따라서, 등호 $D_{KL}(P \parallel Q) = 0$ 는 오직 $c = 1$ 일 때만 성립하며, 이는 다음을 의미:

$$\frac{q(x)}{p(x)} = 1 \Rightarrow p(x) = q(x) \quad \text{for all } x \in \mathcal{X}$$

이는 $D_{KL}(P \parallel Q) = 0$ 은 $P = Q$ 일 때에만 성립함을 증명함

□

문제4. Generalization Bound 이론 유도 및 해석

Stability Bounds (Uniform Stability: Exponential Tail)

High-probability bounds (for any $0 < \delta < 1$). With probability $\geq 1 - \delta$ over $S \sim D^N$:

$$R(A_S) \leq \hat{R}_N(A_S) + 2\beta + (4N\beta + 1) \sqrt{\frac{\ln(1/\delta)}{2N}}.$$

- 접근 방식: Algorithmic Stability
- 증명 목표: 알고리즘이 β -안정적일 때, $1 - \delta$ 의 확률로 실제 위험(True Risk, R)이 훈련 위험(Empirical Risk, $\hat{R}_N$)보다 얼마나 더 나쁠 수 있는지(Generalization Gap)에 대한 상한(Bound)을 제공.

$$R(A_S) \leq \hat{R}_N(A_S) + \underbrace{2\beta + (4N\beta + 1) \sqrt{\frac{\ln(1/\delta)}{2N}}}_{\epsilon: \text{일반화 격차의 상한}}$$

- 증명을 위한 가정:

1. Uniform Stability: 알고리즘 A 가 β -안정적이라고 가정

- $\sup_z |l(A_S, z) - l(A_{S \setminus i}, z)| \leq \beta$
- 학습 데이터셋 S 에서 샘플 하나(z_i)를 뺐을 때($S \setminus i$), 모델의 예측 손실이 어떤 새로운 데이터 z 에 대해서도 최대 β 만큼만 변함. ($\rightarrow \beta$ 가 작을수록 알고리즘이 더 안정적)

2. Bounded Loss: 손실 함수의 값이 항상 일정한 범위에 있다고 가정

- $l(h, z) \in [0, 1]$
- 0-1 loss나 정규화된 MSE 등이 해당

• 증명에 사용된 주요 부등식: McDiarmid's Inequality 활용

- 맥더미드의 부등식은 N 개의 독립적인 변수 $S = \{z_1, \dots, z_N\}$ 를 입력으로 받는 함수 $f(S)$ 에 적용

$$\sup_{S, z'_i} |f(z_1, \dots, z_i, \dots, z_N) - f(z_1, \dots, z'_i, \dots, z_N)| \leq c_i$$

- 이 함수가 Bounded Difference Property를 만족할 때, 즉 i 번째 변수 z_i 하나만 z'_i 로 교체했을 때 함수 값의 최대 변화량이 c_i 로 바운드된다면, 함수 값 $f(S)$ 는 그것의 기댓값 $\mathbb{E}[f(S)]$ 주변에 매우 밀집되어 있음을 보장

$$\mathbb{P}(f(S) - \mathbb{E}[f(S)] \geq \epsilon) \leq \exp\left(\frac{-2\epsilon^2}{\sum_{i=1}^N c_i^2}\right)$$

- 현 증명의 경우, $f(S) = G(S) = R(A_S) - \hat{R}_N(A_S)$ 로 정의하고, $G(S)$ 가 Bounded Difference Property를 만족함을 보일 것.

Proof.

1. Bounded Difference c_i 계산

- 일반화 갭 함수 $G(S) = R(A_S) - \hat{R}_N(A_S)$ 에 대해, 샘플 z_i 하나를 z'_i 로 변경했을 때 $G(S)$ 의 최대 변화량 $c_i = \sup |G(S) - G(S')|$ 를 계산
→ c_i 는 실제 위험 $R(A_S)$ 의 변화량과 경험적 위험 $\hat{R}_N(A_S)$ 의 변화량의 합으로 바운드
- 실제 위험 $R(A_S)$ 의 변화량:
 S 와 S' 는 샘플 z_i 하나만 다르기 때문에 $S^{\setminus i}$ (샘플 i 가 없는 데이터셋)를 활용하여 삼각 부등식을 적용

$$|R(A_S) - R(A_{S'})| \leq |R(A_S) - R(A_{S^{\setminus i}})| + |R(A_{S^{\setminus i}}) - R(A_{S'})|$$

Uniform Stability 가정에 의해, 우변의 두 항은 각각 β 로 바운드됨

$$|R(A_S) - R(A_{S'})| \leq \beta + \beta = 2\beta$$

- 경험적 위험 $\hat{R}_N(A_S)$ 의 변화량:
경험적 위험 $\hat{R}_N(A_S) = \frac{1}{N} \sum_{j=1}^N l(A_S, z_j)$ 의 변화는 $j = i$ 인 항과 $j \neq i$ 인 항들로 나뉨

$$|\hat{R}_N(A_S) - \hat{R}_N(A_{S'})| \leq \frac{1}{N} |l(A_S, z_i) - l(A_{S'}, z'_i)| + \frac{1}{N} \sum_{j \neq i} |l(A_S, z_j) - l(A_{S'}, z_j)|$$

- (a) 항목 i 의 변화: $l(A_S, z_i)$ 가 $l(A_{S'}, z'_i)$ 로 바뀜 → Bounded Loss 가정($l \in [0, 1]$)에 의해, 이 차이는 최대 1임
- (b) 다른 항목 ($j \neq i$)의 변화: 모델이 A_S 에서 $A_{S'}$ 로 변함에 따라, $j \neq i$ 인 각 항목에 대해 실제 위험과 동일하게 삼각 부등식과 안정성 가정을 적용

$$\begin{aligned} |l(A_S, z_j) - l(A_{S'}, z_j)| &\leq |l(A_S, z_j) - l(A_{S^{\setminus i}}, z_j)| + |l(A_{S^{\setminus i}}, z_j) - l(A_{S'}, z_j)| \\ &\leq \beta + \beta = 2\beta \end{aligned}$$

- (c) 따라서 $\hat{R}_N(A_S)$ 의 총 변화량은 다음과 같이 바운드됨

$$\begin{aligned} |\hat{R}_N(A_S) - \hat{R}_N(A_{S'})| &\leq \frac{1}{N} [1 + (N-1)2\beta] \\ &= \frac{1}{N} + 2\beta - \frac{2\beta}{N} \\ &\leq 2\beta + \frac{1}{N} \end{aligned}$$

- $G(S)$ 의 총 변화량 c_i : 위의 두 변화량을 합하여 $G(S)$ 의 총 변화량 c_i 를 바운드

$$\begin{aligned} c_i &\leq |R(A_S) - R(A_{S'})| + |\hat{R}_N(A_S) - \hat{R}_N(A_{S'})| \\ &\leq 2\beta + \left(2\beta + \frac{1}{N}\right) \\ &= 4\beta + \frac{1}{N} \end{aligned}$$

2. 평균 갭 $\mathbb{E}[G(S)]$ 계산

- 일반화 갭의 기댓값 $\mathbb{E}[G(S)]$ 는 $\mathbb{E}[R(A_S)] - \mathbb{E}[\hat{R}_N(A_S)]$ 와 같음
- $\mathbb{E}[R(A_S)]$ 는 $\mathbb{E}_{S, z'}[l(A_S, z')]$ 와 같고, $\mathbb{E}[\hat{R}_N(A_S)]$ 는 $\mathbb{E}_S[\frac{1}{N} \sum l(A_S, z_i)] = \mathbb{E}_{S, S'}[\frac{1}{N} \sum l(A_S, z'_i)]$ 와 같음
- 따라서 $\mathbb{E}[G(S)] = \mathbb{E}_{S, S'} \left[\frac{1}{N} \sum_{i=1}^N (l(A_S, z'_i) - l(A_S, z_i)) \right]$ 로 표현
- S 와 S' 는 동일 분포이므로, 두 번째 항 $l(A_S, z_i)$ 의 기댓값은 $l(A_{S'}, z'_i)$ 의 기댓값과 같음

$$\mathbb{E}[G(S)] = \mathbb{E}_{S, S'} \left[\frac{1}{N} \sum_{i=1}^N (l(A_S, z'_i) - l(A_{S'}, z'_i)) \right]$$

- S' 는 S 와 i 번째 샘플만 다른 데이터셋 $S^{(i \leftarrow z'_i)}$ 으로 볼 수 있기에, 삼각 부등식을 적용하면,

$$|l(A_S, z'_i) - l(A_{S'}, z'_i)| \leq |l(A_S, z'_i) - l(A_{S \setminus i}, z'_i)| + |l(A_{S \setminus i}, z'_i) - l(A_{S'}, z'_i)|$$

- Uniform Stability에 의해 우변의 두 항은 각각 β 로 바운드되므로, $|\dots| \leq \beta + \beta = 2\beta$ 로 도출
- 결론: $\mathbb{E}[G(S)] \leq \mathbb{E} \left[\frac{1}{N} \sum (2\beta) \right] = 2\beta$

$$\mathbb{E}[G(S)] = \mathbb{E}[R(A_S) - \hat{R}_N(A_S)] \leq 2\beta$$

3. 맥더미드의 부등식 조합 및 풀이

맥더미드의 부등식(McDiarmid's Inequality)은 다음과 같음

$$\mathbb{P}(G(S) - \mathbb{E}[G(S)] \geq \epsilon) \leq \exp \left(\frac{-2\epsilon^2}{\sum_{i=1}^N c_i^2} \right)$$

- $\sum c_i^2$ 항 바운드: 앞서 구한 $c_i \leq 4\beta + 1/N$ 를 이용

$$\sum_{i=1}^N c_i^2 \leq \sum_{i=1}^N \left(4\beta + \frac{1}{N}\right)^2 = N \left(4\beta + \frac{1}{N}\right)^2$$

- 우변의 확률을 δ 로 설정하고 ϵ 에 대해 풀이

$$\begin{aligned} \delta &= \exp \left(\frac{-2\epsilon^2}{N(4\beta + 1/N)^2} \right) \\ \ln(1/\delta) &= \frac{2\epsilon^2}{N(4\beta + 1/N)^2} \\ \epsilon^2 &= \frac{N(4\beta + 1/N)^2 \ln(1/\delta)}{2} \\ \epsilon &= \sqrt{\frac{N(4\beta + 1/N)^2 \ln(1/\delta)}{2}} = \left(4\beta + \frac{1}{N}\right) \sqrt{\frac{N \ln(1/\delta)}{2}} \end{aligned}$$

- ϵ 을 N 에 대해 정리

$$\begin{aligned} \epsilon &= \left(4\beta\sqrt{N} + \frac{1}{\sqrt{N}}\right) \sqrt{\frac{\ln(1/\delta)}{2}} \\ &= \left(\frac{4N\beta}{\sqrt{N}} + \frac{1}{\sqrt{N}}\right) \sqrt{\frac{\ln(1/\delta)}{2}} \\ &= (4N\beta + 1) \sqrt{\frac{\ln(1/\delta)}{2N}} \end{aligned}$$

4. 최종 결합

적어도 $1 - \delta$ 의 확률로 $G(S) \leq \mathbb{E}[G(S)] + \epsilon$ 이 성립함.

(Step 2)에서 구한 평균 갭 $\mathbb{E}[G(S)] \leq 2\beta$ 와, (Step 3)에서 구한 $\epsilon = (4N\beta + 1)\sqrt{\frac{\ln(1/\delta)}{2N}}$ 항을 대입.

$$G(S) \leq 2\beta + (4N\beta + 1)\sqrt{\frac{\ln(1/\delta)}{2N}}$$

$G(S) = R(A_S) - \hat{R}_N(A_S)$ 를 다시 대입하여 최종 일반화 경계를 얻을 수 있음

$$R(A_S) - \hat{R}_N(A_S) \leq 2\beta + (4N\beta + 1)\sqrt{\frac{\ln(1/\delta)}{2N}}$$

따라서,

$$R(A_S) \leq \hat{R}_N(A_S) + 2\beta + (4N\beta + 1)\sqrt{\frac{\ln(1/\delta)}{2N}}$$

□

- Leave-one-out (LOO) Risk Bound 또한 갭 함수를 $G'(S) = R(A_S) - R_{loo}(A_S)$ 로 정의하고 동일하게 맥더미드의 부등식을 적용하여 유사하게 유도할 수 있음.

$$R(A_S) \leq R_{loo}(A_S) + \beta + (4N\beta + 1)\sqrt{\frac{\ln(1/\delta)}{2N}}$$

Remark 1. 도출된 Bound의 관련 해석

- 샘플 수 (N): 페널티 항 ϵ 은 $O(1/\sqrt{N})$ 의 속도로 샘플 수 N 에 반비례한다. 즉, N 이 증가할수록 페널티 항은 0에 가깝게 줄어든다. 이는 더 많은 데이터를 사용할수록 훈련 위험($\hat{R}_N$)이 실제 위험($R(A_S)$)을 더 신뢰성 있게 근사함을 의미한다.
- 가설 공간의 복잡도 (β): 본 증명에서 가설 공간의 복잡도는 알고리즘의 안정성 파라미터 β 로 측정된다. 페널티 항 ϵ 은 β 에 선형 비례한다. β 가 클수록, 알고리즘이 샘플 하나에 민감하게 반응하여 페널티가 커진다.
- 신뢰도 (δ): δ 는 이 Bound가 성립하지 않을, 실패 확률이다. 페널티 항 ϵ 은 $\ln(1/\delta)$ 항을 통해 δ 에 의존한다. 더 높은 신뢰도($1 - \delta$)를 위하여 δ 를 0에 가깝게 설정할수록, $\ln(1/\delta)$ 값이 커져 페널티 ϵ 도 커진다. 이는 더 높은 확신을 얻기 위해서는 더 보수적인(더 큰) 오차 범위를 감수해야 함을 의미한다.

Remark 2. 실제 모델 선택 및 일반화 성능과의 관계 해석

- 실제 모델 선택의 궁극적인 목표는 실제위험 $R(A_S)$ 를 최소화하는 것이다. 하지만, $R(A_S)$ 는 직접 계산할 수 없으므로, 본 이론에서 유도된 bound를 따라, $R(A_S)$ 의 상한인 $[\hat{R}_N(A_S) + \epsilon]$ 을 대신 최소화해야 한다. 이때, 훈련오차 $\hat{R}_N(A_S)$ 와 페널티 ϵ 를 모두 최소화하는 것이 중요하다. 다만, 훈련오차 $\hat{R}_N(A_S)$ 와 페널티 ϵ 사이에 trade-off가 존재한다.
 - 모델 복잡도와 과적합: $[\hat{R}_N \rightarrow 0] + [\epsilon \rightarrow \text{high}] \rightarrow$ 높은 실제 위험 (일반화 실패)
 - 모델 단순성과 과소적합: $[\hat{R}_N \rightarrow \text{high}] + [\epsilon \rightarrow 0] \rightarrow$ 높은 실제 위험 (학습 실패)
 - 정규화(Regularization)의 역할: $\hat{R}_N(A_S)$ (훈련 성능)의 하락을 감수하는 대신, 알고리즘을 안정화시켜 (β 를 낮춤) 페널티 항 ϵ 을 낮추는 기법
 - ★ L2 정규화, 앙상블, k-NN 등을 활용 가능
- 일반화 성능을 최적화하기 위해, 정규화를 통해 $[\hat{R}_N(A_S) + \epsilon]$ 의 합이 최소가 되는 모델의 균형점을 찾는 과정이 필요하다.