

Deep Reinforcement Learning–Based Recursive Least Squares–Extended Kalman Filter Framework for Online Parameter Identification and State Estimation of Electric Vehicle Batteries

김민서 이정민 장서현

SYstems **M**odeling and **P**rogramming **L**ab at Yonsei University (**SYMPPLY**)
Department of Industrial Engineering, Yonsei University

IIE8560 Term Project

목차

- I. Introduction: Battery Model Parameter Identification**
- II. RLS-EKF**
- III. DRL-RLS-EKF**
- IV. Numerical Experiments**
- V. Conclusion**

I. Introduction: Background

- EV 환경에서의 상태 추정 필요

- 전기차(EV) 보급 확대 → 배터리 상태 정확한 관리 필요
- **Battery Management System (BMS):** 현재 배터리 상태를 추정하여 충·방전 제어 등 통합 관리
- 상태 추정 필요성:
 - **SoC (State of Charge),** 내부 파라미터를 정확히 알아야 BMS가 정상적으로 제어 가능
 - 실제 주행 환경에서 전압 측정 오차 발생 → 추정 정확도 저하 가능




그림 1. 전기차 배터리 관리 시스템




그림 2. EV 배터리 상태 추정 및 적용 [1]

I. Introduction: Battery Model

- 배터리 동적 거동 모델: Equivalent Circuit Model (ECM)

- 입력: 배터리 전류 (I)
- 출력: 단자 전압(V_{batt})
- 파라미터: $\theta = [R_0, R_1, C_1, R_2, C_2]$
- 상태: 두 회로 내의 전압(V_{RC1}, V_{RC2}), 배터리 충전 상태(SoC)

$$SoC_k = SoC_{k-1} - \frac{I_{k-1} \cdot \Delta t}{3600 \cdot Q}$$

$$V_{RC1,k} = e^{-\frac{\Delta t}{R_1 C_1}} \cdot V_{RC1,k-1} + R_1(1 - e^{-\frac{\Delta t}{R_1 C_1}}) \cdot I_{k-1}$$

$$V_{RC2,k} = e^{-\frac{\Delta t}{R_2 C_2}} \cdot V_{RC2,k-1} + R_2(1 - e^{-\frac{\Delta t}{R_2 C_2}}) \cdot I_{k-1}$$

$$V_k^{model} = OCV(SoC_k) - R_0 \cdot I_k - V_{RC1,k} - V_{RC2,k}$$




그림 3. 2RC-ECM [2]




그림 4. OCV-SoC 함수

I. Introduction: Parameter Identification

- Least Square Method 기반 ECM 모델 파라미터 추정

- 전압 오차 최소화:
$$\min \sum_{t=1}^T \left(V_t^{\text{measured}} - V_t^{\text{model}}(\theta) \right)^2$$
- 한계
 - 전체 데이터를 알고 있다는 가정 하에 최적화 수행
 - 실제 주행 환경이 지속적으로 변함
 - 모델 오차나 측정 잡음과 같은 불확실성 고려 X

- ECM 모델 파라미터 변화

- 저항(R), 커패시터(C)는 온도 · SoC 변화에 따라 동적으로 달라짐
 - 예) 온도가 낮아지면 내부 저항 증가
- 주행 중 환경 변화에 따라 배터리 모델 파라미터 변함




그림 5. 주행 사이클 내 셀 전압 변화




그림 6. 환경 조건에 따른 파라미터 [3]

I. Introduction: Objective

- **Online Parameter Identification / State Estimation**

- 입력·전압·상태가 시간에 따라 변하므로 **실시간 업데이트 필요**
- 실제 주행 환경에서 측정 잡음·모델 오차 등 **불확실성 존재**
- **파라미터 추정**: Recursive Least Square Method를 통해 업데이트
 - Forgetting factor를 이용하여 파라미터 변화와 불확실성에 대응
- **상태**: Extended Kalman Filter를 통해 업데이트
 - 측정 잡음·모델 오차를 확률적으로 반영하여 상태 업데이트

- **강화학습과 RLS-EKF의 결합**

- RLS-EKF 결합 추정 구조의 안정성 · 수렴성 개선 필요
 - RLS: 과거 데이터의 영향 정도를 조절하여 파라미터 변화에 대응
 - EKF: 예측(prior)과 측정 업데이트의 비중 조정




그림 7. 실시간 배터리 파라미터/상태 추정 [4]

II. RLS-EKF: Kalman Filter

- Kalman Filter(KF)란?

- 모델의 **예측값**과 노이즈가 포함된 **관측값**을 바탕으로 현재 **상태**를 재귀적으로 업데이트하는 **베이지안 추정 알고리즘**
- 프로세스 노이즈(Q)와 측정 노이즈(R)가 **Gaussian 분포**를 가지고 시스템이 **Linear** 하다고 가정
- 비선형 시스템에서는 **Extended Kalman Filter(EKF)**로 확장하여 적용


- KF 알고리즘

1. 예측 단계

- 이전 상태(x_{k-1}^+)와 입력(u_{k-1})을 받아 상태 전이 모델(F)을 통해 **Prior 상태(x_k^-)** 및 **공분산(P_k^-)** 예측

2. 업데이트 단계

- 측정 노이즈(R)와 관측 모델(H)을 이용 $\Rightarrow$ Kalman Gain(K) 계산
- 실제 측정값(y_k)을 이용하여 예측을 보정 $\Rightarrow$ **Posterior 상태(x_k^+)** 및 **공분산(P_k^+)** 업데이트



II. RLS-EKF: Recursive Least Square

- Recursive Least Square(RLS)란?

- 이전 데이터와 현재 입력을 이용하여 실시간으로 추정하는 **Online Least Square 알고리즘**
- Forgetting Factor(λ)**: 알고리즘의 수렴 속도와 잡음에 대한 민감도를 결정 (convergence $\leftrightarrow$ sensitivity)


- RLS 알고리즘

- 예측 단계

- 이전 파라미터 추정값(θ_{k-1}^+)을 $\text{Prior}(\theta_k^-)$ 로 두고 공분산을 **forgetting factor(λ)**에 따라 조정


- 업데이트 단계

- 입력 벡터(ϕ_k)와 공분산을 이용 $\Rightarrow$ RLS Gain(L_k)을 계산
- 실제 측정값(y_k)을 이용하여 예측을 보정 $\Rightarrow$ **Posterior 파라미터(θ_k^+)** 및 **공분산(P_k^+) 업데이트**




II. RLS-EKF: Kalman Filter & Recursive Least Square

- Dynamic Systems에서의 ECM



- RLS-EKF를 통한 ECM 상태/파라미터 추정

- ECM에서 추정해야 하는 대상들의 특성에 따라 상태와 파라미터로 나누어 추정
- RLS로 배터리 모델의 파라미터를 추정하고, EKF로 배터리의 상태를 추정하는 재귀적 구조



II. RLS-EKF: Kalman Filter & Recursive Least Square

- RLS의 Forgetting Factor(λ)

- 알고리즘의 수렴 속도와 잡음에 대한 민감도를 결정 (convergence $\leftrightarrow$ sensitivity)
 - $\lambda \approx 1$: 느린 변화에 안정적으로 수렴하여 노이즈에 강함
 - $\lambda < 1$: 최신 변화에 빠르게 적응 하여 급변 환경에 유리함
- 작은 λ : 과거 정보가 급격히 망각되어 파라미터가 발산할 위험 발생
- 큰 λ : 적응 속도가 느려 파라미터 변화 포착이 지연되어 정확성 저하

- RLS에서 고정 Forgetting Factor(λ)의 문제점

- Tracking Lag

- 고정된 λ 는 실제 주행 환경에서 SOC, 온도, 노화 등에 따라 불규칙하게 변하는 파라미터의 특성을 고려하지 못함
 $\Rightarrow$ 최신 변화를 적절하게 반영하지 못함

- Wind-Up


- 동일한 λ 를 적용하는 방식은 각 파라미터의 특성을 반영하여 추정하기 않음 $\Rightarrow$ 오차가 증폭

- Data Saturation

- 배터리가 일정 상태로 오랫동안 머무르면 입출력 관계가 거의 변하지 않음 $\Rightarrow$ 더 이상 업데이트가 되지 않음


II. RLS-EKF: 구조 개선

- KF에서 고정 Process/Measurement Noise(Q, R)의 문제점
 - 실제 운행 Dynamic 반영 불가능
 - 실제 배터리 충·방전과 운행은 복잡한 물리/화학 프로세스로 잡음 특성은 시간에 따라 변함
- Adaptive RLS-EKF
 - 실시간으로 적절한 **Adaptive Hyperparameter 제어**를 통해 RLS-EKF의 안정성을 개선하는 구조
 - 기존 Rule-based 또는 Offline 튜닝 방식[5][6] $\Rightarrow$ 일반화 성능이 **부족**하고 높은 설계 **복잡도**를 가짐




II. RLS-EKF: 방법론 확장

- **Model-based + Data-driven: Hybrid 상태/파라미터 추정**
 - ECM 기반 Model-based 추정법의 물리적 해석 가능성과 Data-driven 기법의 적응성·고차원 학습 능력을 결합
⇒ 정확도 · 안정성 · 적응성을 모두 확보한 **Hybrid 추정 구조**로 확장
- **강화학습 기반의 제어 프레임워크**
 - ECM 기반 파라미터/상태 추정의 신뢰성 유지하면서 **강화학습**을 통한 Adaptive 튜닝 구조 제안
 - 강화학습을 활용해 RLS-EKF의 λ, Q, R 을 실시간으로 조정 ⇒ 추정의 **정확도**와 **일반화** 성능 향상



III. DRL-RLS-EKF: 프레임워크

- **Adaptive Controller 구성: 강화학습(DRL) 활용**
 - 상태에 따라 일관된 액션(λ, Q, R 조정)이 필요 → 파라미터 추정의 안정성 좌우
 - 일관된 행동전략 학습 → 정책최적화 → **강화학습** 활용 용이
- RLS-EKF 구조를 MDP로 추상화하고 강화학습을 통해 **하이퍼파라미터 (λ, Q, R)를 실시간으로 조정**



- **구조적 이점**
 - 기존 RLS-EKF 구조의 해석력 및 안정성 유지 + 환경 및 시간 변화에 적응 가능한 tuning 실현
 - Fixed, offline, rule-based tuning의 한계를 극복하고 목적 지향적인 **적응성 확보**

III. DRL-RLS-EKF: 학습 알고리즘

- ① 초기화: 초기 상태 추정값 x_0 , 공분산 P_0 , Q , R , λ , DRL agent 파라미터 θ , Replay buffer
- ② 각 에피소드마다:
 - RLS-EKF 상태 초기화 + 시뮬레이션 환경 리셋
- ③ 타임스텝 루프 (1~T):
 - **DRL agent interaction:**
 - **State** (RLS gain, Kalman gain, innovation)를 agent에 입력 → **Action** (λ , Q , R) 출력 → 필터에 즉시 반영
 - **RLS:** ECM 모델 파라미터 추정
 - **EKF:** Kalman gain K_t 계산, 추정치 업데이트, 공분산 업데이트
 - **Reward** (예측 전압 오차) 계산 → **next state**로 이동
- ④ 경험 저장 및 학습: Replay buffer에 (state, action, reward, next state) 저장 및 Replay buffer 기반 **policy update**
- ⑤ 학습 종료 후 **policy** 저장 및 적용

III. DRL-RLS-EKF: Environment 내부 구조

Action (λ, Q, R 결정)

$$\mathbf{a}_t = [a_1, a_2, a_3, a_4, a_5, a_6, a_7, a_8, a_9, a_{10}]$$

Reward (예측전압오차)

$$r_t = -(V_k^{model} - V_k^{meas})^2$$


State (RLS-EKF 시스템 내부 및 환경 상태)

$$\mathbf{s}_{t+1} = [\ell_1, \ell_2, \ell_3, \ell_4, \ell_5, \ell_6, k_1, k_2, k_3, \epsilon_k, V_k^{meas}, I_k, T_k]$$

$$\lambda_k = [a_5, a_6, a_7, a_8, a_9, a_{10}]^T \quad Q_k = \begin{bmatrix} a_1 & 0 & 0 \\ 0 & a_2 & 0 \\ 0 & 0 & a_3 \end{bmatrix} \quad R_k = a_4$$


$$\Lambda_k = \text{diag}(\lambda_k)$$

$$L_k = [\ell_1, \ell_2, \ell_3, \ell_4, \ell_5, \ell_6]^T \quad K_k = [k_1, k_2, k_3]^T \quad \epsilon_k = y_k - h(x_k^-)$$




III. DRL-RLS-EKF: DDPG Agent 활용

- 대표적인 연속 제어 알고리즘 4가지 (DDPG, TD3, SAC, PPO) 중 실험을 통해 **DDPG 선택**
 - 실험적으로 충전구간을 포함한 전압 오차를 최소화하고 학습의 빠른 수렴성을 보인 알고리즘
- DDPG 특징 및 구조**
 - Actor는 주어진 상태 s_t 에 따른 **deterministic** action a_t 출력
 - 학습과정 중에 actor는 탐색을 위해 액션에 노이즈 N_t 를 추가해서 environment에서 경험 수집
 - 초기 학습 방향성이 중요



III. DRL-RLS-EKF: DDPG 학습구조 확장

- Baseline 모델만으로도 효과적인 성능 구현 가능하지만, 학습구조의 확장으로 추가적인 개선 가능



IV. Numerical Experiments: 실험 세팅

- 실험 계획 및 목적

1. DRL-RLS-EKF(제안 알고리즘)의 성능 평가: 알고리즘의 안정성 평가
2. LS(Least Square) vs RLS-EKF 성능 비교: 불확실성 고려에 따른 파라미터 추정 차이 분석
3. RLS-EKF vs DRL-RLS-EKF 성능 비교: 적응형 하이퍼파라미터 튜닝의 효과 분석


- 성능 평가 기준

1. 예측전압오차: $(V_k^{model} - V_k^{meas})^2 < 0.005$ (V)
2. 파라미터의 해석력: 파라미터의 절대적인 답은 없으나, 물리/화학적으로 해석가능한 범위 존재
 - $0.0001 \leq R_0, R_1, R_2$ (저항) ≤ 0.001 , $1000 \leq C_1, C_2$ (커패시턴스) ≤ 10000
 - OCV(개방회로전압): 데이터 기반 회귀분석 모델과의 비교
3. RLS-EKF 시스템의 대응성: 상태변화에 따른 DDPG agent의 액션 다양성을 통해 확인

- 실험 세팅

- RLS-EKF 시스템 초기값: 일반화 과정을 통한 별도의 알고리즘 활용하여 구성
- DDPG 초기값: batch_size=256, buffer_size=2e+5, warmup_steps=500, train_every=10, lr=1e-6, seq_len=10

IV. Numerical Experiments: DRL-RLS-EKF 성능 평가



1. 예측전압오차

모든 사이클에서 우수한 전압 RMSE($<1e-10$) 확인
: ECM 모델 예측 정확성 = 파라미터 추정 정확성


2. 파라미터 해석력

- ① 해석가능한 범위 내의 R_0, R_1, R_2, C_1, C_2 추정
- ② 파라미터의 변동폭이 작음
- ③ 참조용 OCV와 추정 OCV 사이 유사도 높음

3. RLS-EKF 시스템의 대응성

DDPG의 액션이 상태에 따라 변화됨을 확인

IV. Numerical Experiments: LS vs RLS-EKF 성능 비교




✓ LS: 전구간 전압 최소화하는 $[R_0, R_1, R_2, C_1, C_2]$ 추정

- ① offline 추정만 가능
- ② 주행구간이 길어질수록 전압오차 증가
- ③ 긴 주행 구간에 대한 하나의 파라미터만 추정
→ 배터리의 상태변화 표현 불가

✓ RLS-EKF: 고정된 λ, Q, R 을 활용한 $[R_0^t, R_1^t, R_2^t, C_1^t, C_2^t]$ 시간별 추정

- ① online 추정 가능
- ② 새로운 측정값에 대한 prior 보정 및 posterior 갱신으로 파라미터 보정
→ 전압 오차 감소
- ③ 단, 파라미터의 해석력을 위해 RLS-EKF 시스템은 파라미터 별 특성을 반영하여 튜닝되어야함 → 시스템(λ, Q, R)의 adaptiveness 필요

IV. Numerical Experiments: RLS-EKF vs DRL-RLS-EKF 성능 비교



- RLS-EKF: 고정된 $\lambda, Q, R \rightarrow [R_0^t, R_1^t, R_2^t, C_1^t, C_2^t]$ 시간별 추정 vs DRL-RLS-EKF: DRL 기반 시간별 $\lambda^t, Q^t, R^t \rightarrow [R_0^t, R_1^t, R_2^t, C_1^t, C_2^t]$ 시간별 추정
- 상태에 따라 λ, Q, R 이 변화하는 DRL-RLS-EKF의 물리적으로 일관된 파라미터 추정치 및 낮은 전압오차 확인

V. 결론 및 향후계획

- 2RC-ECM 파라미터의 실시간 추정과 SOC 상태 추정의 연계 프레임워크
- 기존 RLS-EKF의 한계 극복을 위해 대량의 학습데이터를 통해 **실시간성과 일반화 성능을 동시에 보장하는 강화학습 기반의 제어 프레임워크** 제안
 - 해석력을 갖춘 안정적인 파라미터 추정이 가능함을 확인
- **보완 요소:** 파라미터-상태 간 물리적 일관성(**Parameter Consistency**) 확보
 - e.g.) SOC $\uparrow \rightarrow$ 저항 $\downarrow$, 온도 $\uparrow \rightarrow$ 저항 $\downarrow$, etc

❖ 참고문헌

- [1]: S. G. Padder et al. (2025). Data-Driven Approaches for Estimation of EV Battery SoC and SoH: A Review. (2025). *IEEE Access*, 13, 35048–35067.
- [2]: Bouchareb, H., Saqli, K., M'sirdi, N. K., & Oudghiri Bentaie, M. (2024). Adaptive Joint Sigma-Point Kalman Filtering for Lithium-Ion Battery Parameters and State-of-Charge Estimation. *World Electric Vehicle Journal*, 15(11), 532.
- [3]: Huang, Y., Wang, S., Wang, Z., & Xu, G. (2024). Investigation of Lithium-Ion Battery Negative Pulsed Charging Strategy Using Non-Dominated Sorting Genetic Algorithm II. *Electronics*, 13(11), 2178.
- [4]: Li, C., & Kim, G. W. (2024). Improved state-of-charge estimation of lithium-ion battery for electric vehicles using parameter estimation and multi-innovation adaptive robust unscented Kalman filter. *Energies*, 17(1), 272.
- [5] K. Kim et al. (2020) A New Update Rule of ADFF-RLS & EKF based Joint-estimation Filters for Real-time SOC/SOH Identification. arXiv: 2003.09839
- [6] Rijanto, Estiko, et al. RLS with optimum multiple adaptive forgetting factors for SoC and SoH estimation of Li-Ion battery. 2017 5th International Conference on Instrumentation, Control, and Automation (ICA). IEEE, 2017.
- [7]: Kim, M., Kim, K., Kim, J., Yu, J., & Han, S. (2018). State of charge estimation for lithium-ion battery based on reinforcement learning. *IFAC-PapersOnLine*, 51(28), 404-408.

감사합니다.

김민서 이정민 장서현

SYstems **M**odeling and **P**rogramming **L**ab at Yonsei University (**SYMP**LY)
Department of Industrial Engineering, Yonsei University

IIE8560 Term Project